

Steam 游戏商店大数据分析报告

课程：大数据应用 · 期末项目
团队：罗马 (Roma)
成员：罗景楠、马亦麟
代码仓库：<https://github.com/yilinpotato/BigData-App>

1. 引言与数据集介绍

电子游戏是全球最大的数字娱乐产业之一，Steam 是 PC 平台最主要的游戏分发渠道。本项目对 Steam 商店约 2.7 万款游戏的结构化数据进行大数据分析，挖掘市场结构、定价规律、用户粘性、平台战略等方面的规律，完整演练 HDFS 存储 → PySpark 清洗 → Spark SQL 分析 → 可视化 的大数据处理流程。

数据集来自 Kaggle [Steam Store Games \(Clean Dataset\)](#)，由 SteamSpy 与 Steam Storefront API 抓取（2019 年快照），共 6 个 CSV、约 242 MB，以 appid 为主键关联：

文件	行数	内容
steam.csv	27,075	主表：名称、发行日期、开发/发行商、平台、类型、好评/差评数、游玩时长、拥有量、价格
steamspy_tag_data.csv	29,022	标签宽表（约 370 个标签列，值为投票数）
steam_description_data.csv	174,903	游戏描述文本
steam_media_data.csv	27,332	图片/截图/视频链接（嵌套 JSON）
steam_requirements_data.csv	27,319	配置要求（含 HTML）
steam_support_info.csv	27,136	官网/客服链接

本报告的核心分析基于 steam.csv（主表）与 steamspy_tag_data.csv（标签）。

2. 系统架构与 HDFS 存储 / 访问策略

2.1 技术栈

层	组件	版本
存储	Hadoop HDFS（单机伪分布式）	3.3.6
计算	Apache Spark / PySpark	3.5.5
查询	Spark SQL	3.5.5
运行时	OpenJDK	17 (Temurin)
可视化	matplotlib / seaborn	—

整个栈在 WSL2 + Ubuntu 22.04 上以用户级、无需 root 的方式部署。

2.2 HDFS 存储策略

采用「原始区 + 清洗区」分层的数据湖式组织：

```
hdfs:///steam/raw/      原始 CSV（不可变，留档）
hdfs:///steam/clean/    清洗后的列式数据
├─ games/              主表，Parquet，按 release_year 分区
└─ tags_long/          标签长表，Parquet
```

设计要点：

- 原始/清洗分离：原始 CSV 上传到 /steam/raw 后保持只读，所有加工产物写入 /steam/clean，保证可追溯、可重跑。
- 列式 + 压缩（Parquet）：清洗后由行式 CSV 转为 Parquet，列式存储 + 内置压缩，显著降低分析时的 I/O，并保留 schema 与类型。
- 分区（Partitioning）：主表按 release_year 分区，使「按年份」的查询能分区裁剪（partition pruning），只扫描相关年份目录。
- 副本数=1：单节点环境设 dfs.replication=1，避免无谓冗余。

2.3 访问方式与工程难点

- HDFS 守护进程以 `hdfs --daemon start namenode/datanode` 直接启动，绕开 `start-dfs.sh` 对 SSH 免密登录的依赖（WSL 下无 `sshd`），实现无 root 单机部署。
- Spark 通过 `spark.read.parquet("hdfs://localhost:9000/steam/clean/games")` 直接读 HDFS。
- 工程中解决了三个真实问题，并固化到脚本：① Java 17 与 Hadoop 的模块访问限制——为守护进程注入 `--add-opens`；② 工作目录含空格导致 Hadoop FsShell 的本地路径 URI 解析失败——用硬链接把数据暴露到无空格目录再 put；③ Spark 本地落盘目录重定向到无空格路径。

全部启动脚本见仓库 `setup/`（`00_install_stack.sh` / `01_start_hdfs.sh` / `02_load_data.sh` / `env.sh`）。

3. 数据预处理（Spark 清洗管线）

清洗管线 `src/clean_pipeline.py` 从 HDFS 读原始 CSV，输出清洗后的 Parquet，关键步骤：

1. 类型转换：release_date → date、评价数/时长 → 整型、price → double、布尔字段转换。
2. 派生字段：
 - positive_ratio = positive / (positive + negative)（好评率）
 - total_ratings、is_free（价格为 0）
 - owners_low / owners_high / owners_mid：将拥有量区间字符串（如 10000000-20000000）解析为上下界与中位估计
 - num_genres / num_categories / num_platforms 及 on_windows / on_mac / on_linux 平台布尔
3. 多值字段处理：platforms / categories / genres / steamspy_tags 以 ; 分隔，分析时用 explode 展开。
4. 缺失值与异常处理：过滤无 appid 或空 name 的记录、appid 去重、负价归零。
5. 宽表转长表：标签宽表（约 370 列）用 Spark stack() 转为长表（appid, tag, votes）并过滤 votes > 0，由约 1,000 万稀疏单元压缩为 215,633 条有效记录。


清洗结果：主表 27,075 行（全部有效），整体平均好评率 0.714，免费游戏 2,560 款。

4. 分析问题、方法与发现

围绕 8 个分析问题，统一以 Spark SQL / DataFrame API 计算聚合结果，再用 matplotlib/seaborn 可视化。完整代码见 `notebooks/steam_analysis.ipynb`，SQL 见 `sql/analysis_queries.sql`。

Q1 年度发行趋势


方法：按 `release_year` 分组计数（Spark SQL）。



发现：发行量在 2014 年后爆发式增长，2018 年达峰值 8,159 款；93%（25,242 款）的游戏在 2014 年及以后发行。这与 Steam 2017 年开放 Steam Direct、独立游戏大量涌入直接相关；2019 因数据为年中快照而回落。

Q2 热门类型及其口碑

方法：`explode(genres)` 后按类型聚合数量与平均好评率。




发现：Indie（19,419）、Action（11,903）、Casual（10,210）、Adventure（10,031）数量领先。

但数量多不等于口碑好——各类型平均好评率集中在 0.63–0.73，休闲/竞速/暴力类略低，核心向类型相对更稳。

Q3 价格 × 口碑 × 拥有量


方法：价格分桶后聚合平均好评率与平均拥有量；并统计免费/付费占比。



发现：付费游戏中位价仅 £3.99，定价高度集中于低价区。关键反差：最低价区 (<£5, 13,285 款) 平均好评率最低 (0.684)、平均拥有量也最低 (约 4.7 万)，是典型的"走量但偏低质"长尾；而 £10–40 中端游戏好评率最高 (约 0.75)，免费游戏与中高价精品则拥有量最大 (免费约 44 万)。即"低价不等于走量，免费与精品才走量"。

Q4 游玩时长 × 类型 (用户粘性)


方法：在有一定评价量的样本上，按类型聚合平均游玩时长。



发现：大型多人 (MMO, 约 17.6 小时)、免费网游 (13 小时)、RPG (8.5 小时)、策略 (6.3 小时) 粘性最强。强粘性高度依赖可重复游玩机制 (多人对战、长期养成/经营)，休闲解谜类时长最短。

Q5 Top 开发商 / 发行商


方法：按开发商计数；按发行商累计好评数排序（Spark SQL）。



发现：发行数量最多的是量产型工作室（Choice of Games 94 款、KOEI TECMO 72 款）；而累计口碑高度集中于头部发行商——Valve（527 万好评）一骑绝尘，其后为育碧、Bethesda、PUBG、Rockstar。数量与影响力并不等同：头部靠少数爆款贡献了绝大多数正面评价。

Q6 平台支持趋势


方法：统计整体平台占比，及 Mac/Linux 支持率随年份变化。



发现：Windows 支持率 100%，Mac 29.8%、Linux 19.3%。Mac/Linux 支持率在 2013–2015 年（SteamOS / Steam Machine 推广期）见顶，随该战略降温而回落——平台覆盖与厂商商业战略强相关。

Q7 最受欢迎标签


方法：在标签长表上按 tag 汇总投票数（Spark SQL）。



发现：投票最高的标签为 action（76.4 万）、indie（73.0 万）、adventure、multiplayer、singleplayer，与 Q2 的类型分布互相印证；玩家心智中的标签更偏“玩法体验”（如 singleplayer、atmospheric）。

Q8 成就数量 × 口碑 / 时长

方法：按成就数量分桶，比较平均好评率与平均时长。



发现：有成就的游戏好评率（0.74–0.78）整体高于无成就（0.704），并在 51–100 个成就时好评率最高（0.779）；游玩时长随成就数单调上升（100+ 成就达 14.2 小时）。说明成就作为正反馈/留存机制与满意度、粘性正相关，但数量过多边际收益递减。

5. 结论

1. 市场结构：Steam 自 2014 年起进入独立游戏井喷期，Indie/Action/Casual 在数量上主导，但同质化也压低了长尾产品的口碑。
2. 商业规律：定价集中于低价区，但低价 $\neq$ 走量——<£5 多为低质长尾，免费与中高价精品才同时获得高拥有量；中端定价口碑最佳。
3. 用户粘性：多人 / 网游 / RPG / 策略类时长最长，粘性源于可重复游玩与长期养成机制。
4. 平台与机制：跨平台支持随厂商战略（SteamOS）起落；成就系统与玩家满意度、留存正相关。

6. 反思与局限

- 数据为 2019 年快照，无法反映近年趋势；owners 为区间估计、price 为英镑计价，分析结论偏宏观。
- 缺少真实文本评论，好评率只能由 positive/negative 计数近似，无法做情感细分。
- 未深入解析 description / requirements 中的文本与 HTML 字段。后续可：解析描述做 NLP 主题/情感分析、引入时间序列建模、用标签共现做社区/聚类分析。
- 工程上单机 HDFS 仅作教学演示，真实场景应为多节点集群并引入 Hive/数据治理。

7. 团队分工

成员	主要分工
罗景楠	数据工程：HDFS 环境搭建、数据入库、Spark 清洗管线 (setup/、src/clean_pipeline.py)
马亦麟	分析与可视化：8 个分析问题的 Spark SQL、图表与解读 (notebooks/、sql/)
共同	报告撰写、结果验证与演示

(以上分工为初稿，可按实际贡献调整。)

附录：环境与复现

```
git clone https://github.com/yilinpotato/BigData-App.git
cd BigData-App
bash setup/00_install_stack.sh    # 安装 Hadoop (首次)
bash setup/01_start_hdfs.sh      # 启动单机 HDFS
bash setup/02_load_data.sh       # CSV 入 HDFS
source setup/env.sh
python src/clean_pipeline.py      # 清洗 → Parquet
# 打开 notebooks/steam_analysis.ipynb 运行分析
```